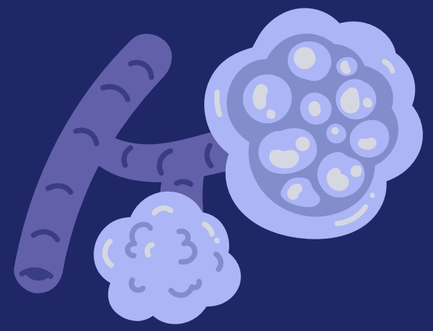

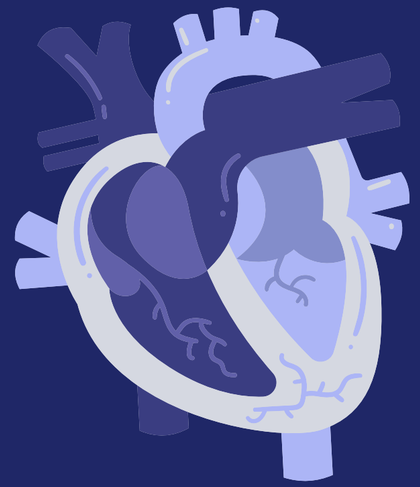

AKCİĞER KANSERİ VERİ SETİ ANALİZİ

SÜMEYRA AKKAYA

EDİBA USLU

AKCİĞER KANSERİ NEDİR?

TANIM: AKCIĞER DOKUSUNDAKI HÜCRELERIN IHTIYAÇ DIŞI VE KONTROLSÜZ ÇOĞALMASIYLA ORTAYA ÇIKAN BIR TÜMÖR HASTALIĞIDIR.

VERİ SETİNİN AMACI

- **İNSANLARIN KANSER RISKLERINI DÜŞÜK MALIYETLE ÖĞRENMELERI**
- **VERI ANALIZI VE MAKINE ÖĞRENMESI KULLANMAK.**
- Veri seti: 309 kişi, 16 özellik
- Hedef: “Akciğer kanseri var mı, yok mu?” tahmini yapmak.

KULLANDIĞIMIZ KÜTÜPHANELER

- numpy : Matematiksel işlemler
- pandas : Veri analizi ve tablo işlemleri
- matplotlib & seaborn : Grafik çizimi
- sklearn : Model kurma ve değerlendirme
- warnings : Gereksiz uyarıları gizler
- requests, PIL, BytesIO : Görsel dosyaları indirme ve işleme

3. VERİ İNCELEMESİ

- DF.HEAD() # İLK 5 SATIR
- DF.SHAPE # KAÇ SATIR VE SÜTUN
- DF.INFO() # VERİ TİPLERİ VE EKSİK DEĞERLER

- Veri seti: 309 satır, 16 sütun
- Eksik değer yok

4. DOSYA KONTROLÜ

```
import os
for dirname, _, filenames in os.walk('/kaggle/input'):
for filename in filenames:
print(os.path.join(dirname, filename))
```

- **VERI DOSYASININ KONUMUNU BULUR.**
- Çıktı: /kaggle/input/lung-cancer/survey lung cancer.csv

4. SÜTUN TANIMLARI

1. GENDER → Cinsiyet
2. AGE → Yaş
3. SMOKING → Sigara içme durumu
4. YELLOW_FINGERS → Sarı parmaklar
5. ANXIETY → Anksiyete
6. PEER_PRESSURE → Akran baskısı
7. CHRONIC DISEASE → Kronik hastalık
8. FATIGUE → Yorgunluk
9. ALLERGY → Alerji
10. WHEEZING → HIRILTI
11. ALCOHOL CONSUMING → ALKOL KULLANIMI
12. COUGHING → ÖKSÜRÜK
13. SHORTNESS OF BREATH → NEFES DARLIĞI
14. SWALLOWING DIFFICULTY → YUTMA GÜÇLÜĞÜ
15. CHEST PAIN → GÖĞÜS AĞRISI
16. LUNG_CANCER → KANSER DURUMU

🔍 5. VERI OKUMA

```
df = pd.read_csv("../input/lung-cancer/survey lung cancer.csv")
df.head()
```

- **VERI SETINI OKUR VE ILK 5 SATIRI GÖSTERIR.**
- **HER SATIR BIR KIŞIYI TEMSIL EDER**

6.VERI MANIPÜLASYONU

```
FOR COL IN DF.COLUMNS:
        if col != 'LUNG_CANCER':
DF[COL] = DF[COL].REPLACE({'1': 0, '2': 1})
```

- **"EVET" VE "HAYIR" DEĞERLERINI 0 VE 1 OLARAK DÖNÜŞTÜRÜR.**
- Bilgisayarın veriyi sayısal olarak işlemesini sağlar.

📈 7. VERI ÖZETI

```
df.describe()
df.isnull().sum()
df.duplicated().sum()
df.drop_duplicates(inplace=True)
```

- **DESCRIBE() : ORTALAMA, MIN, MAX DEĞERLERI GÖSTERIR.**
- isnull() : Eksik veri kontrolü
- **DUPLICATED() : YINELENEN SATIRLARI BULUR**
- drop_duplicates() :Yinelenenleri siler

📊 8. GÖRSELLEŞTIRME

```
SNS.COUNTPLOT(DATA=DF, X='SMOKING', HUE='LUNG_CANCER', PALETTE='COOLWARM')
plt.title("Sigara Kullanımı ve Akciğer Kanseri Dağılımı")
```

- SIGARA IÇENLERDE KANSER ORANINI GÖSTERIR.
- RENKLI ÇUBUK GRAFIĞI ILE GÖRSEL ANALIZ YAPILIR.

9. SÜTUN BAZLI DAĞILIMLAR

```
for column in df.columns[:-1]:
count = df.groupby([column, 'LUNG_CANCER']).size().unstack(fill_value=0)
print(count)
```

- HER ÖZELLIK ILE KANSER DURUMU ARASINDAKI ILIŞKIYI GÖSTERIR.
- ÖRNEĞIN: SIGARA IÇENLERDE KANSER ORANI DAHA YÜKSEK.

10. YAŞ ANALIZI

```
sns.boxplot(x=df["LUNG_CANCER"], y=df["AGE"])
sns.kdeplot(df[df["LUNG_CANCER"] == 0]["AGE"], fill=True)
sns.kdeplot(df[df["LUNG_CANCER"] == 1]["AGE"], fill=True)
```

- **BOXPLOT → YAŞ DAĞILIMINI GÖSTERIR.**
- **KDE PLOT → KANSER OLAN VE OLMAYANLARIN YAŞ YOĞUNLUĞU.**

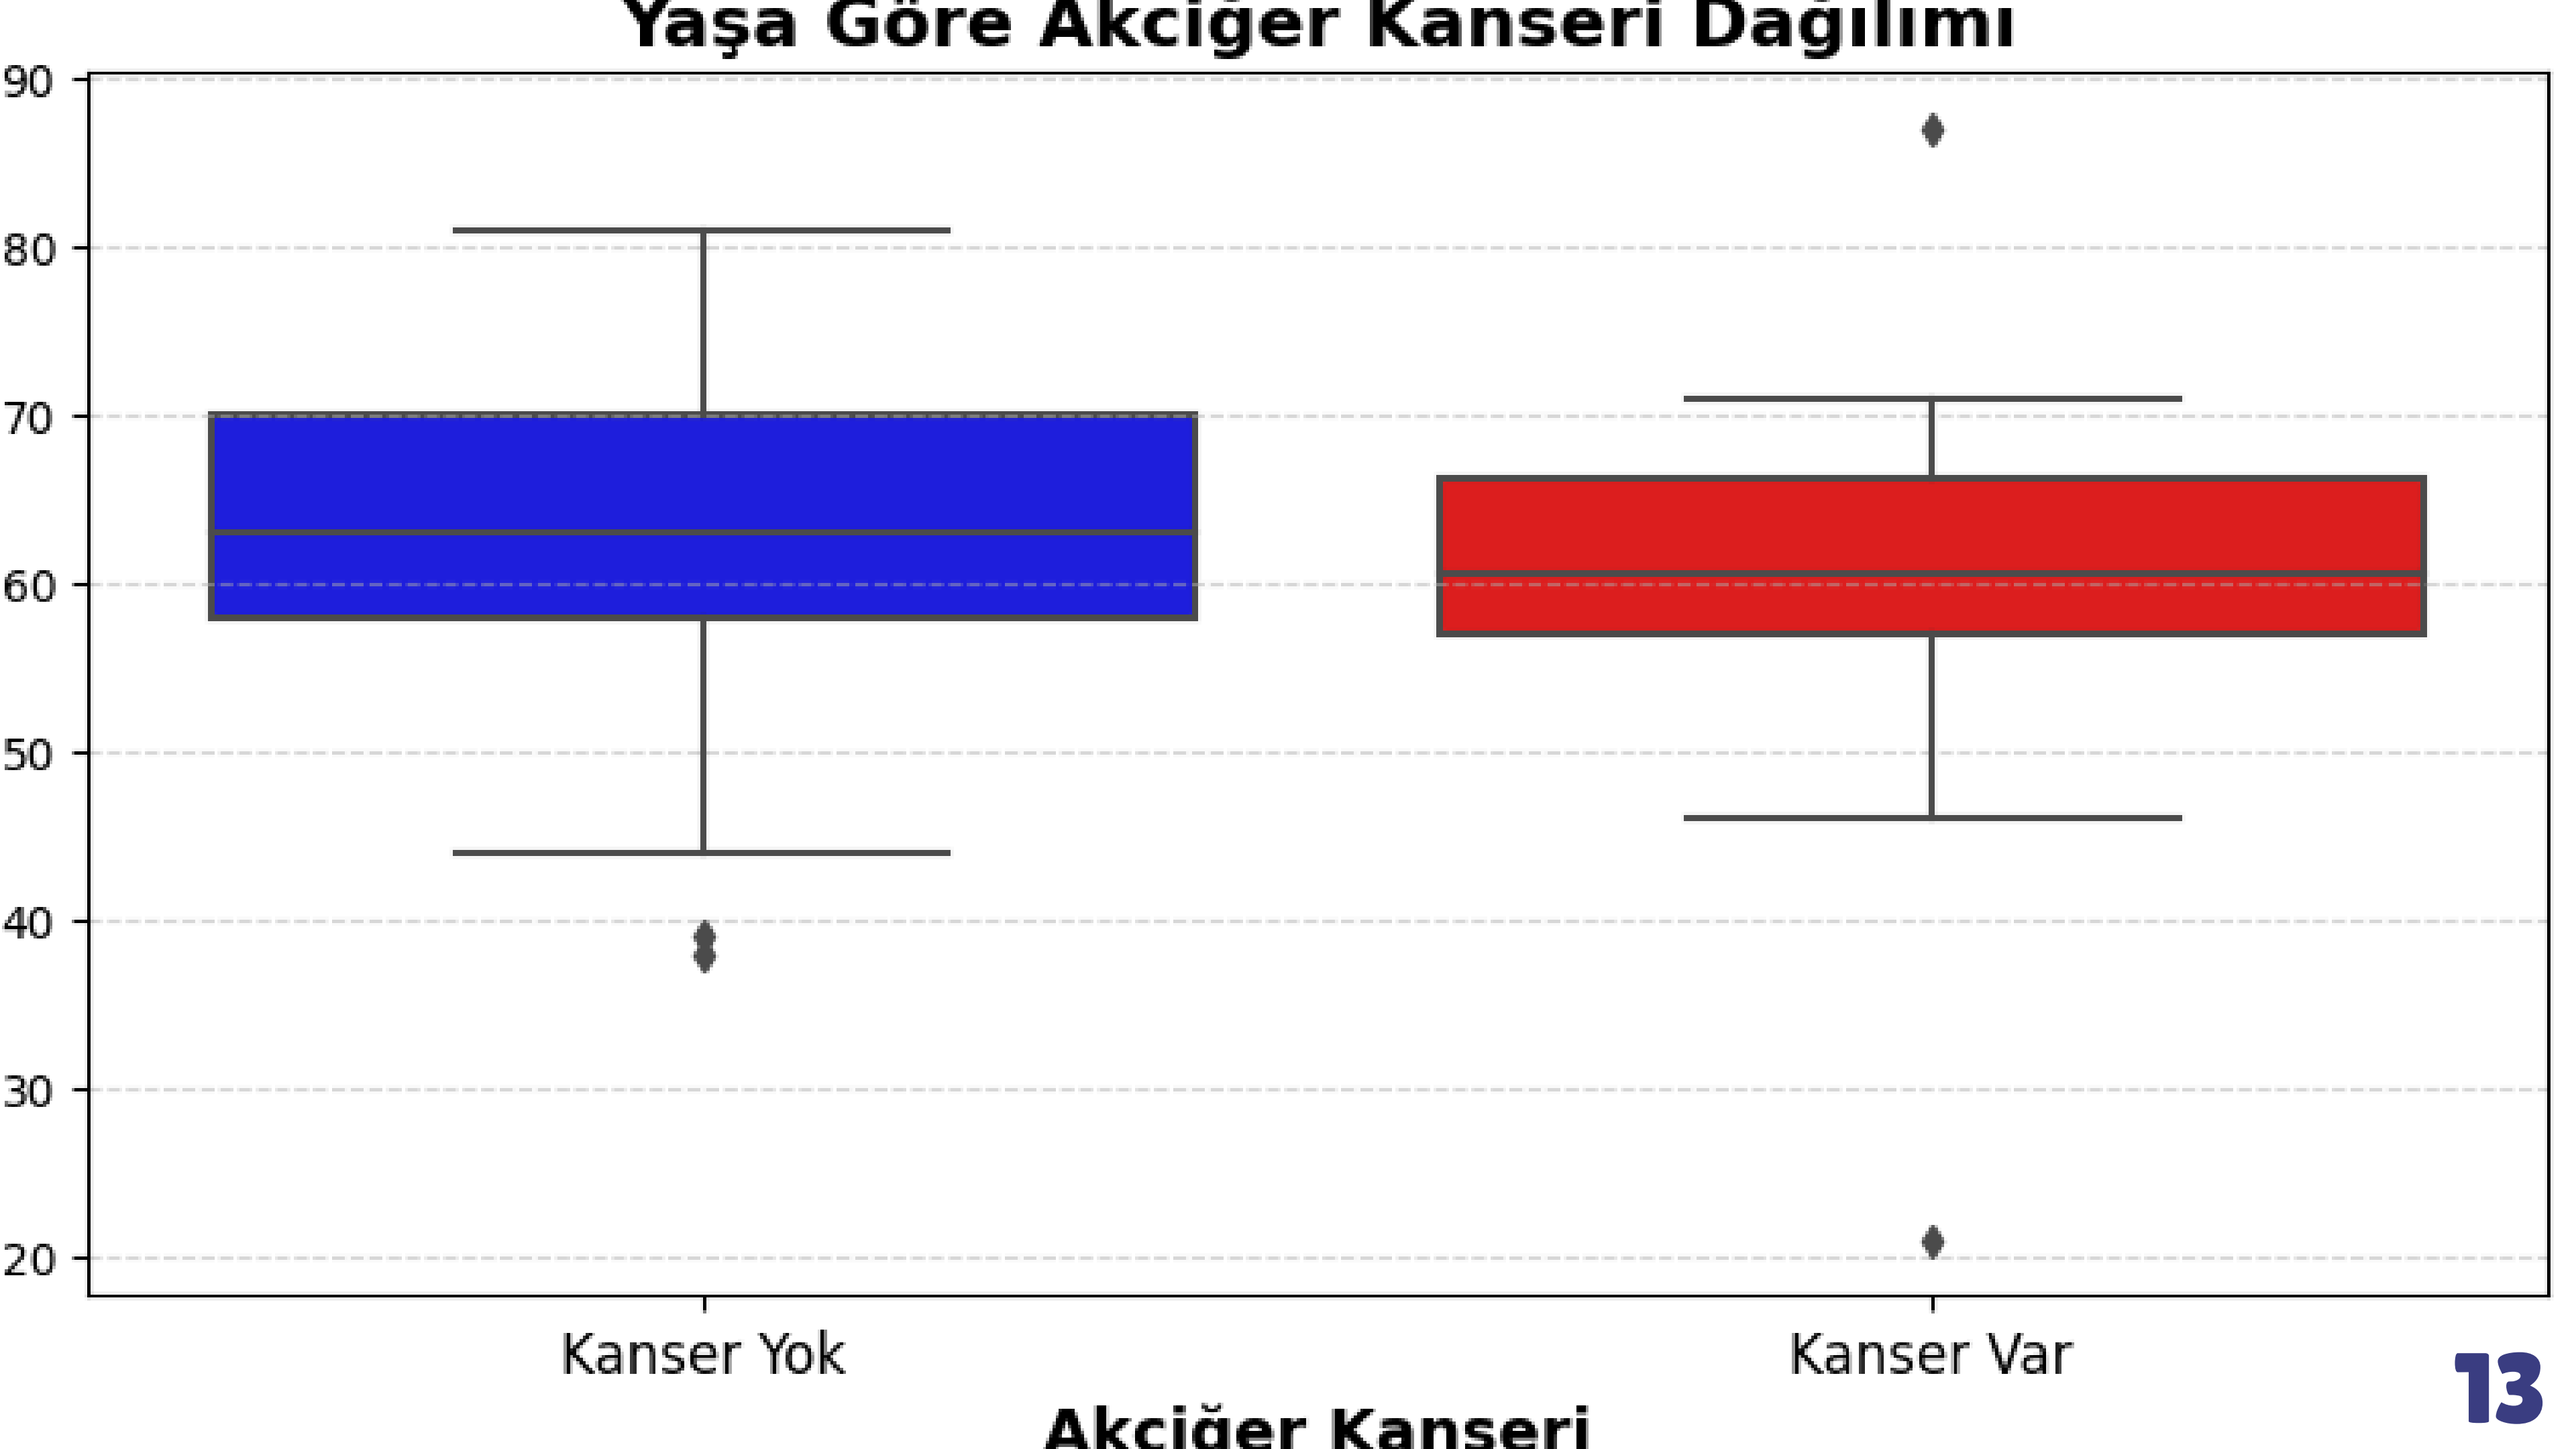
Yaşa Göre Akciğer Kanseri Dağılımı
90
80
70
60
50
40
30
20
Kanser Yok
Kanser Var
Akciğer Kanseri

11. ETIKETLEME

```
ENCODER = LABELENCODER()
DF['LUNG_CANCER']=ENCODER.FIT_TRANSFORM(DF['LUNG_CANCER'])
DF['GENDER']=ENCODER.FIT_TRANSFORM(DF['GENDER'])
```

- METIN DEĞERLERI SAYIYA DÖNÜŞTÜRÜR.
- ÖRNEĞIN: KADIN=0, ERKEK=1; KANSER YOK=0, VAR=1

12. MODEL KURMA

```
X = DF.DROP(COLUMNS=['LUNG_CANCER'])   # BAĞIMSIZ DEĞIŞKENLER
Y = DF['LUNG_CANCER']                  # BAĞIMLI DEĞIŞKEN (HEDEF)

X_TRAIN, X_TEST, Y_TRAIN, Y_TEST = TRAIN_TEST_SPLIT(
    X, Y, TEST_SIZE=0.2, RANDOM_STATE=42
)

SCALER = STANDARDSCALER()
X_TRAIN = SCALER.FIT_TRANSFORM(X_TRAIN)
X_TEST = SCALER.TRANSFORM(X_TEST)
```

- X (FEATURES / ÖZELLIKLER): YAŞ, SIGARA, YORGUNLUK, HIRILTI GIBI KANSER RISKINI ETKILEYEN TÜM SÜTUNLAR. MODELIN ÖĞRENMESI IÇIN KULLANILAN GIRDI VERILERI.
- Y (TARGET / HEDEF): MODELIN TAHMIN ETMEYE ÇALIŞTIĞI ÇIKTI VERISI.

- X_TRAIN VE Y_TRAIN (EĞITIM VERISI): VERININ %80'I. → ALGORITMANIN ÖĞRENDIĞI KISIM. ÖRNEK: "BU ÖZELLIKLERE SAHIP KIŞILERDE KANSER VAR/YOK."
- X_TEST VE Y_TEST (TEST VERISI): VERININ %20'SI. → ALGORITMANIN SINANDIĞI KISIM. ÖRNEK: "MODEL YENI KIŞILERI DOĞRU TAHMIN EDEBILIYOR MU?"

- STANDARDSCALER → VERILERI AYNI ÖLÇEĞE GETIRIR

13. LOJISTIK REGRESYON MODELI

- LOJISTIK REGRESYON KANSER VAR/YOK TAHMINI YAPAR.
- MODEL EĞITILIR.

```
MODEL = LOGISTICREGRESSION(PENALTY='L2', C=1.0, SOLVER='LBFGS', MAX_ITER=1000)
MODEL.FIT(X_TRAIN, Y_TRAIN)
```

14. MODEL PERFORMANSI

- ACCURACY: %92.86
- PRECISION & RECALL: MODELIN DOĞRULUK VE HASSASIYET ORANLARI.

"MODEL 100 KIŞIDEN YAKLAŞIK 93'ÜNÜ DOĞRU TAHMIN EDIYOR."

15. ROC-AUC GRAFIĞI

```
fpr, tpr, _ = roc_curve(y_test, y_pred_prob)
roc_auc = auc(fpr, tpr)
plt.plot(fpr, tpr, label=f'ROC AUC = {roc_auc:.2f}')
```

- **MODELIN BAŞARI ORANINI GÖRSEL OLARAK GÖSTERIR.**
- **ROC AUC = 0.93 → YÜKSEK DOĞRULUK.**

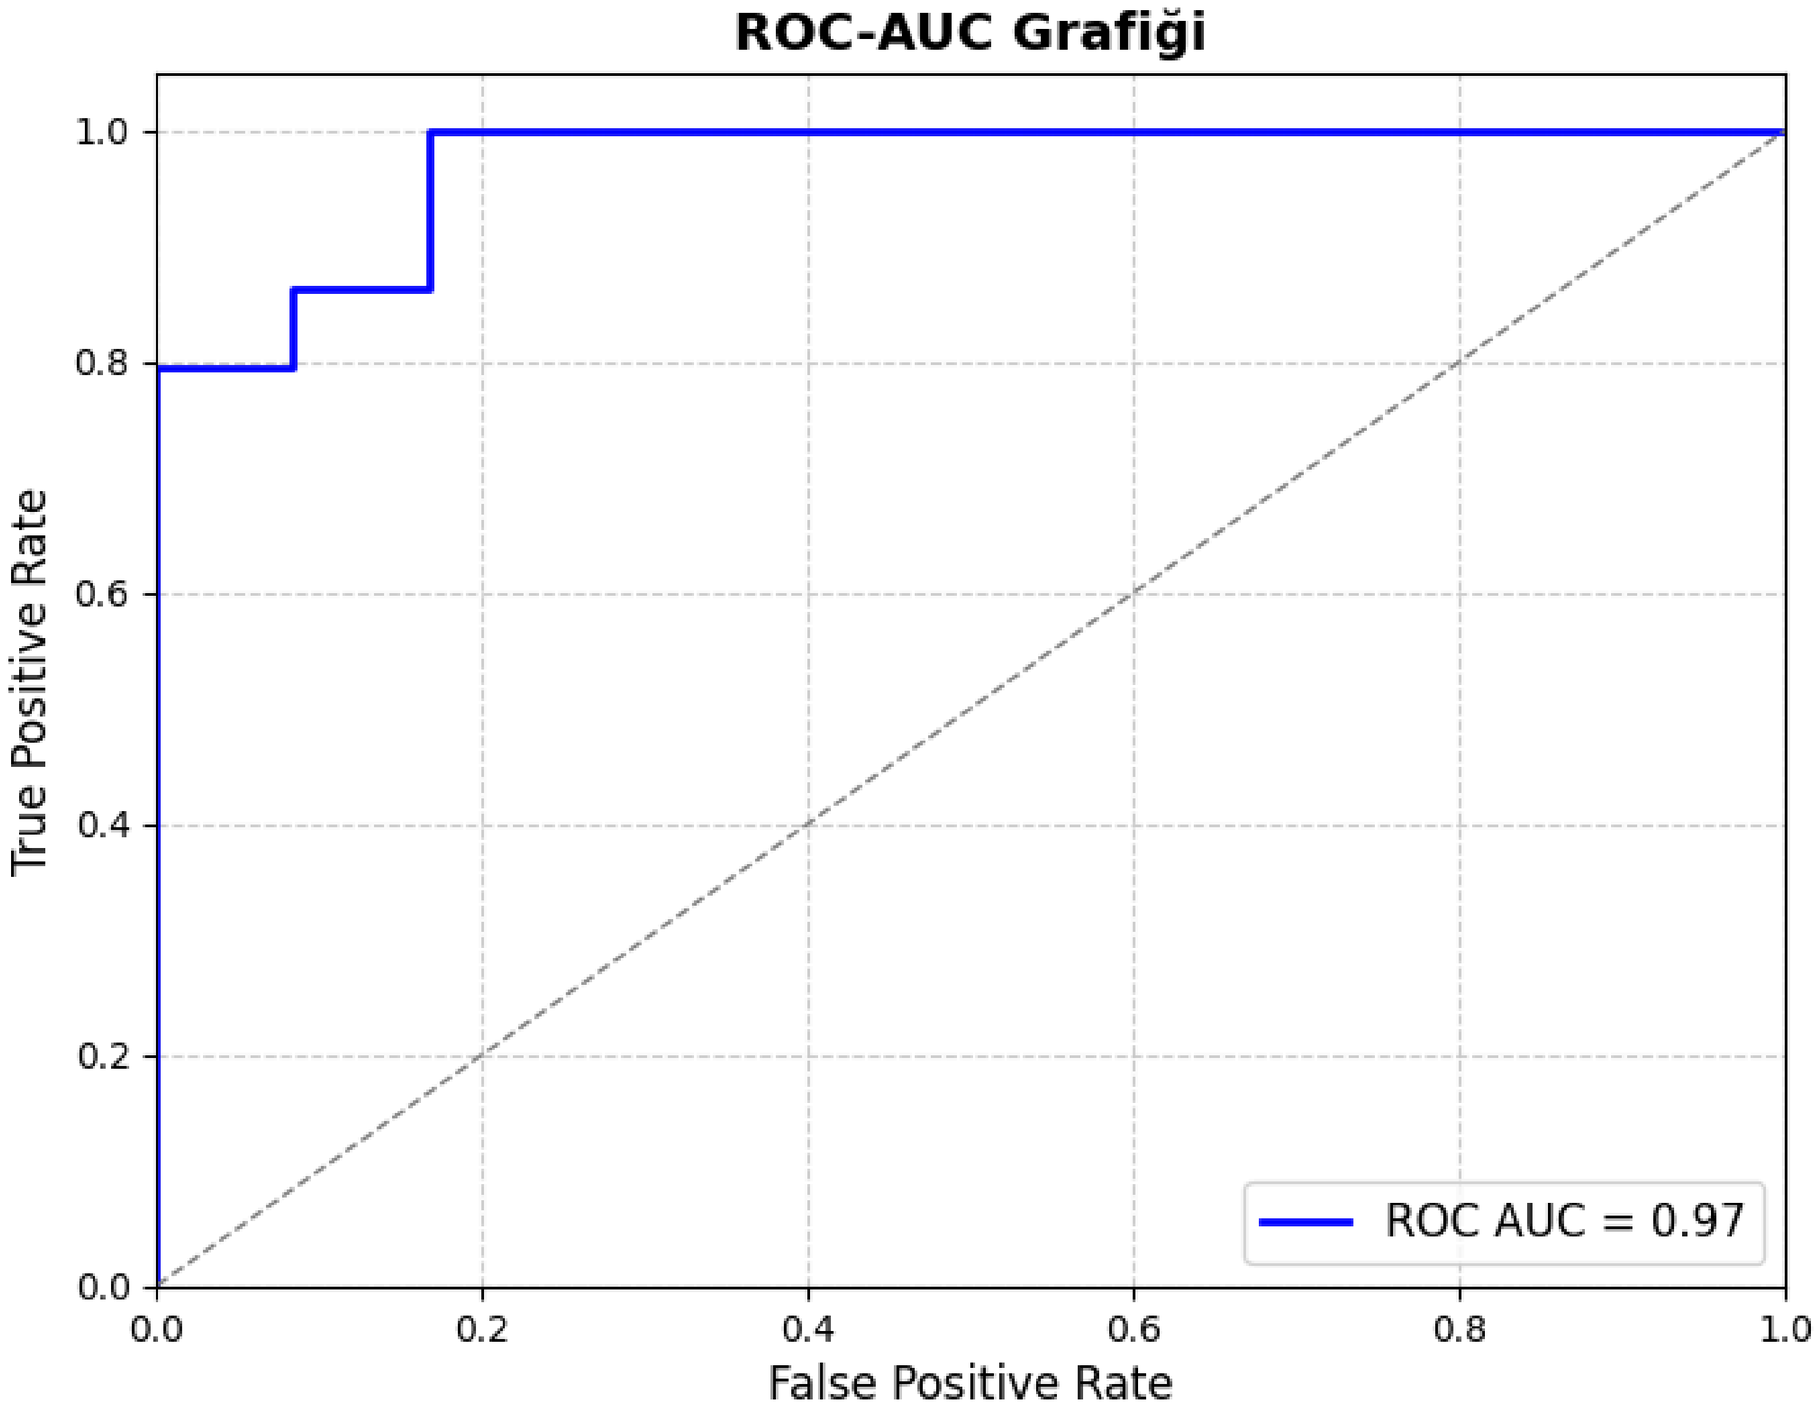
ROC-AUC Grafiği
True Positive Rate
False Positive Rate
0.0
0.2
0.4
0.6
0.8
1.0
ROC AUC = 0.97

16.SONUÇ

- MODEL %93 DOĞRULUKLA TAHMIN YAPABILIYOR.
- SIGARA, YAŞ, YORGUNLUK VE HIRILTI GIBI FAKTÖRLER KANSER RISKINI ARTIRIYOR.
- VERI TEMIZLIĞI VE GÖRSELLEŞTIRME, MODEL BAŞARISINI GÜÇLENDIRDI.

DINLEDIĞINIZ IÇIN TEŞEKKÜRLER

EDIBA USLU

SÜMEYRA AKKAYA